

Segmentação de Rentabilidade e Risco no Varejo

Visão Geral

Este projeto analisa pedidos de um conjunto de dados de vendas no varejo. O objetivo é entender o que influencia a margem de lucro e separar pedidos de alto risco dos mais estáveis.

Por que isso importa

Negócios do varejo perdem dinheiro ao aplicar descontos ou políticas de envio sem conhecer o impacto. Este projeto mostra padrões que ajudam a reduzir perdas e melhorar a margem.

O que foi feito

- Limpeza e estruturação do conjunto de dados
- Criação de variáveis relacionadas a localização, categoria, envio e descontos
- Teste de múltiplos modelos:
 - - Lasso/Ridge (modelo base, ajuste ruim)
 - - GAMLS com distribuição t (melhor ajuste, mas resíduos bimodais)
 - - XGBoost / LightGBM (alta acurácia, baixa interpretabilidade)
 - - Modelo final: Mistura de Regressões Lineares Gaussianas com modelo concomitante

Principais Resultados

- Cluster 1 (Alto Risco):
 - - Participação nos pedidos: 31,4%
 - - Participação nas margens negativas: 40%
 - - Margem média: -13,2%
- Cluster 2 (Estável):
 - - Participação nos pedidos: 68,6%
 - - Margem média: 23,5%

Impacto no Negócio

- Os pedidos do Cluster 1 geraram um total de \$677 em perdas no período.
- Uma mudança de política direcionada a esse grupo poderia reduzir as perdas em aproximadamente 67,86%.

- Principais fatores de custo no Cluster 1: Desconto, Subcategoria Mesas/Estantes, Região (Mountain).

O que fazer com isso

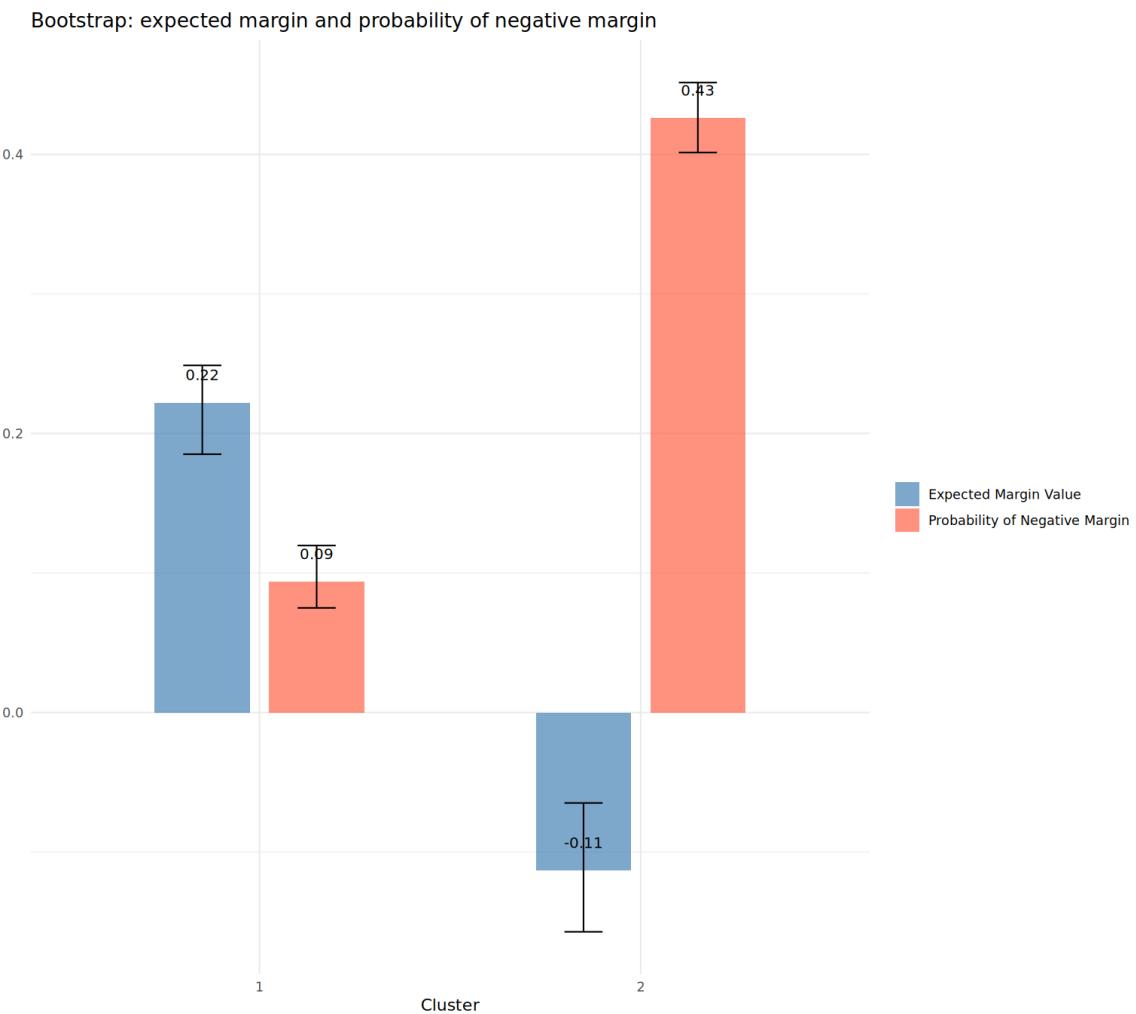
- Revisar todas as regras de desconto
- Reavaliar a estratégia de precificação para Mesas, Estantes, Suprimentos e Máquinas
- Marcar pedidos de risco antecipadamente usando as probabilidades do modelo

Validação do Modelo

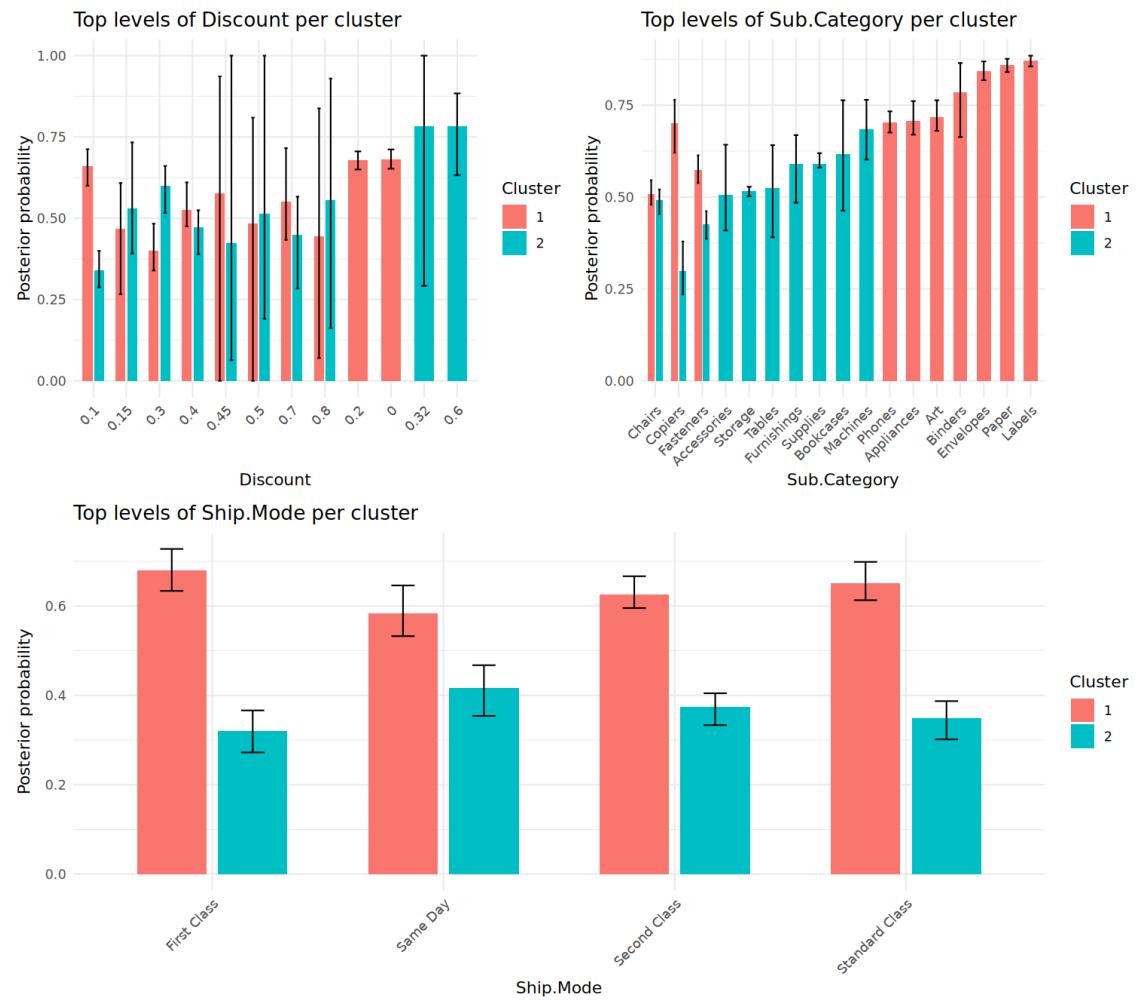
- O algoritmo EM foi estável após cerca de 10 reinicializações aleatórias
- Validação via bootstrap com 1000 reamostragens
- Métricas de desempenho:
 - RMSE (fora da amostra): 0.06713472
 - R^2 (fora da amostra): 0.9786957

Visualizações

1. Trade-off risco vs. retorno entre clusters

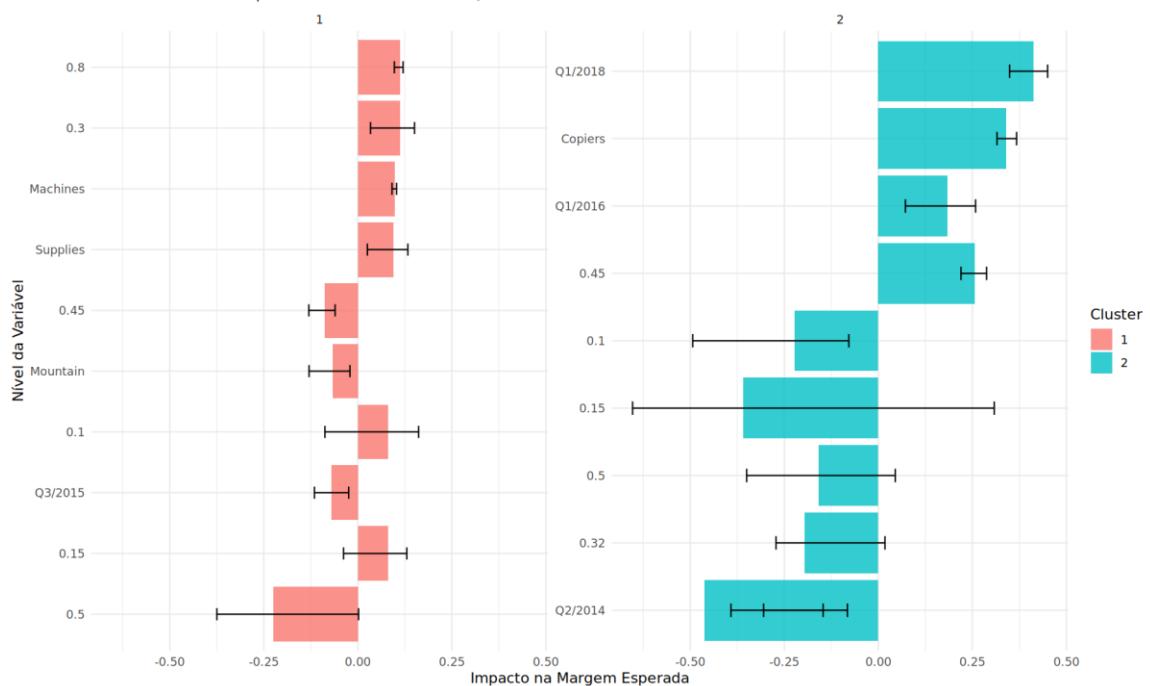


2. Fatores operacionais de alta performance



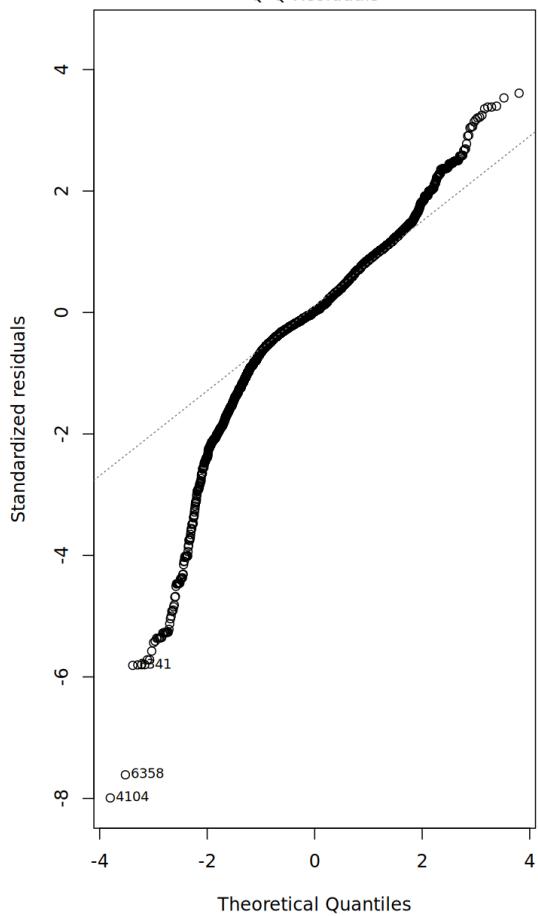
3. 10 níveis mais impactantes por cluster

Top 10 Níveis com Maior Impacto por Cluster
 Barras = Efeito Médio | Linhas = IC 95% via Bootstrap

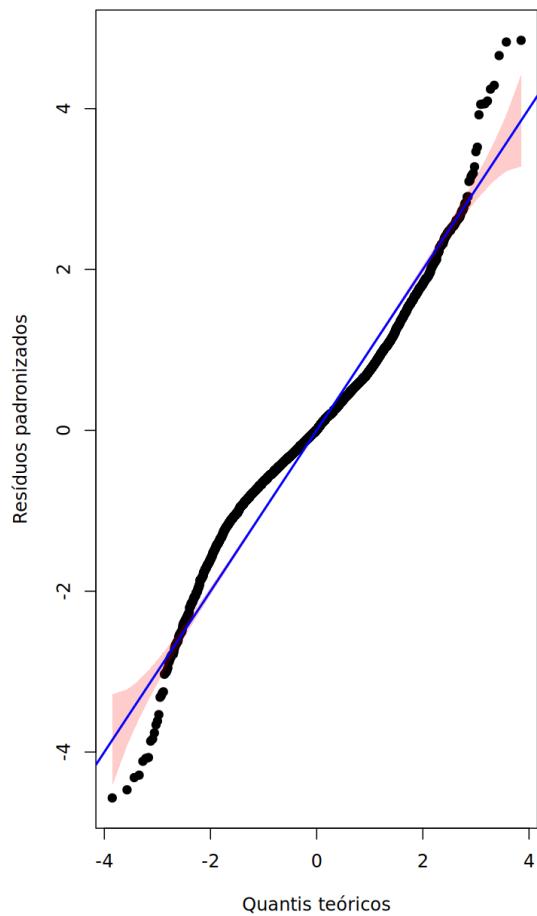


4. Comparação de resíduos entre modelos

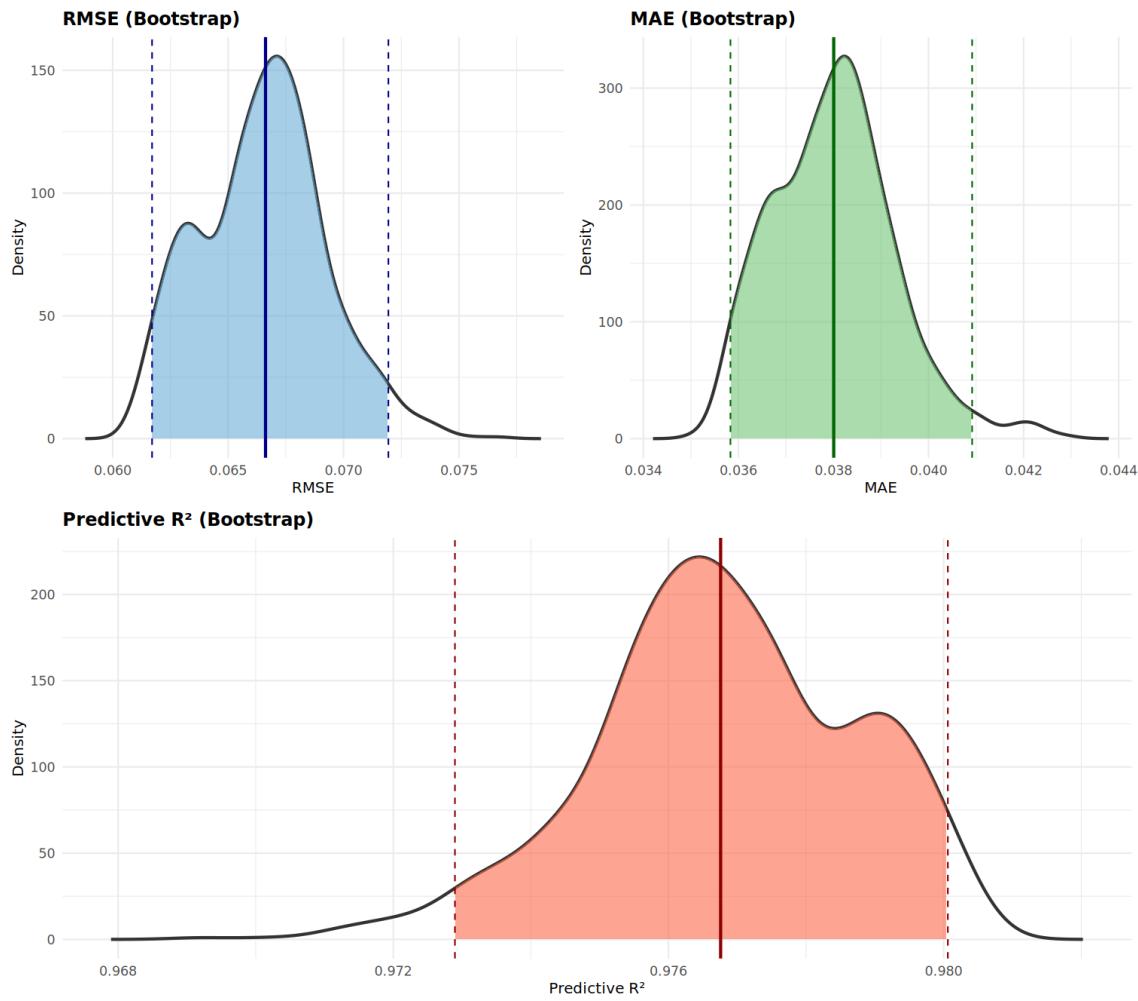
heavy tails suggests t-student distribution
Q-Q Residuals



Q-Q plot com banda de 90%



5. Validação via bootstrap



6. Principais fatores de custo no Cluster 1

	Variavel	Nivel	Lucro_Medio	Contagem
	<chr>	<chr>	<dbl>	<int>
1	Discount	0.5	-340.	53
2	Discount	0.45	-206.	9
3	Discount	0.8	-111.	259
4	Discount	0.4	-108.	178
5	Discount	0.7	-92.7	353
6	Discount	0.32	-92.6	24
7	Discount	0.3	-44.7	194
8	Sub.Category	Tables	-44.6	264
9	Discount	0.6	-40.2	123
10	division	West South Central	-14.7	977
11	Sub.Category	Bookcases	-13.9	190
12	Sub.Category	Supplies	-8.83	164
13	Sub.Category	Machines	-4.46	100
14	division	Mountain	-3.55	498